

การตรวจจับพฤติกรรมของผู้ขับขี่ยานพาหนะ

Object Detection

Detect Driving Behavior

ธนิตชา จินดารา¹, วชิรญาณ ศรีนวล², สุชาพุฒิ ประณีตทอง³, อภิวัฒน์ เกษสาวงศ์⁴

Thanitcha Jindara¹, Wachiraya Srinual², Suchaphut Praneetthong³, Apiwat Ketsawong⁴

s6506021620121@email.kmutnb.ac.th¹, s6506021620172@email.kmutnb.ac.th²

s6506021620202@email.kmutnb.ac.th³, s6506021620211@email.kmutnb.ac.th⁴

บทคัดย่อ

งานวิจัยนี้นำเทคนิคการตรวจจับวัตถุ (Object Detection) และตรวจจับพฤติกรรมของผู้ขับขี่ยานพาหนะ โดยใช้โมเดลเชิงลึกในการเรียนรู้รูปแบบพฤติกรรมจากชุดข้อมูลภาพและวิดีโอที่รวบรวมจากสภาพการขับขี่จริง ระบบที่พัฒนาขึ้นสามารถจำแนกพฤติกรรมที่หลากหลาย เช่น การใช้โทรศัพท์มือถือขณะขับรถ สูบบุหรี่ หรือการง่วงนอนระหว่างขับขี่ จากการทดลองพบว่าโมเดลสามารถตรวจจับและจำแนกพฤติกรรมของผู้ขับขี่ได้อย่างมีประสิทธิภาพ ซึ่งชี้ให้เห็นถึงศักยภาพของโมเดลที่สามารถนำไปใช้พัฒนาระบบช่วยเหลือการขับขี่เพื่อลดอุบัติเหตุบนท้องถนน และสนับสนุนการบังคับใช้กฎหมายจราจรอย่างมีประสิทธิภาพ

คำสำคัญ – เทคนิคการตรวจจับวัตถุ

ABSTRACT

This research applies object detection techniques and detects driver behaviors by using a deep model to learn behavior patterns from image and video datasets collected from real driving conditions. The developed system can classify various behaviors, such as using a mobile phone while driving, smoking, or drowsiness while driving. The experiments show that the model can detect and classify driver behaviors effectively, which indicates the potential of the model to develop driving assistance systems to reduce road accidents and support effective traffic law enforcement.

Keywords – object detection

1. บทนำ

การขับขี่ยานพาหนะเป็นกิจกรรมที่ต้องใช้สมาธิและความระมัดระวังอย่างสูง เนื่องจากพฤติกรรมของผู้ขับขี่ส่งผลโดยตรงต่อความปลอดภัยบนท้องถนน อย่างไรก็ตาม อุบัติเหตุทางถนนยังคงเป็นปัญหาระดับโลกที่ก่อให้เกิดการสูญเสียทั้งชีวิตและทรัพย์สิน โดยหนึ่งในสาเหตุหลักของอุบัติเหตุคือพฤติกรรมที่ไม่ปลอดภัยของผู้ขับขี่ ซึ่งรวมถึงการใช้โทรศัพท์มือถือระหว่างขับขี่ การง่วงนอนและความอ่อนล้า รวมถึงการรับประทานอาหารขณะขับรถ

พฤติกรรมเหล่านี้ส่งผลให้ความสามารถในการตอบสนองต่อสถานการณ์ฉุกเฉินลดลง เช่น การใช้โทรศัพท์มือถือทำให้ผู้ขับขี่เสียสมาธิจากสภาพแวดล้อมบนท้องถนน การง่วงนอนหรืออ่อนล้าส่งผลให้การตอบสนองต่อเหตุการณ์ที่ไม่คาดคิดล่าช้าลง และการรับประทานอาหารระหว่างขับขี่อาจทำให้เกิดการควบคุมพวงมาลัยได้ไม่เต็มประสิทธิภาพ ด้วยเหตุนี้ การตรวจจับและจำแนกพฤติกรรมของผู้ขับขี่จึงเป็นสิ่งสำคัญที่สามารถช่วยลดอุบัติเหตุและเพิ่มความปลอดภัยบนท้องถนน

งานวิจัยนี้มุ่งเน้นการนำเทคนิคการเรียนรู้เชิงลึกและการตรวจจับวัตถุ (Object Detection) มาประยุกต์ใช้ในการจำแนกพฤติกรรมของผู้ขับขี่ยานพาหนะ โดยใช้ข้อมูลภาพและวิดีโอเป็นแหล่งข้อมูลหลัก ระบบที่พัฒนาขึ้นจะสามารถระบุและแยกแยะพฤติกรรมที่อาจเป็นอันตรายได้อย่างแม่นยำ ซึ่งสามารถนำไปใช้เป็นเครื่องมือสำหรับหน่วยงานที่เกี่ยวข้องหรือระบบช่วยเหลือการขับขี่อัตโนมัติเพื่อเพิ่มความปลอดภัยในการเดินทาง


2. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 โครงข่ายประสาทเทียม

โครงข่ายประสาทเทียม เป็นศาสตร์แขนงหนึ่งของทางด้านปัญญาประดิษฐ์ (Artificial Intelligence : AI) มีรูปแบบโครงสร้างและการทำงานของโครงข่ายประสมผลเหมือนกับสมองของสิ่งมีชีวิตซึ่งมีปรับเปลี่ยนตัวเองต่อการตอบสนองของอินพุตตามกฎของการเรียนรู้ (Learning rule) หลังจากที่ได้เรียนรู้สิ่งที่ต้องการแล้ว โครงข่ายนั้นจะสามารถทำงานที่กำหนด

2.2 การเรียนรู้เชิงลึก

การเรียนรู้เชิงลึก (Deep Learning) [1] คือ เป็นอัลกอริทึมที่เรียนรู้โดยอัตโนมัติใช้โครงข่ายประสาทหลายชั้น (Layer) เหมือนแบบจำลองโครงข่ายประสาทของมนุษย์ (Neurons) และทำการเรียนรู้ข้อมูล โดยใส่ข้อมูลเข้าไปและทำงานเป็นลำดับขั้นขั้นแรกคือชั้นรับข้อมูล (Input Layer) เป็นชั้นที่รับข้อมูลหรือฟีเจอร์ จากนั้นเครื่องจักรจะนำข้อมูลไปประมวลผลในชั้นที่สองคือชั้นซ่อน (Hidden Layer) เพื่อปรับค่าน้ำหนักแล้วเมื่อคำนวณค่าน้ำหนักกับข้อมูลและปรับค่าผลลัพธ์ด้วยฟังก์ชันกระตุ้นแล้วจะนำเสนอข้อมูลผลลัพธ์ไปยังชั้นแสดงผล (Output Layer) ข้อดีของการเรียนรู้เชิงลึกคือผู้พัฒนาไม่จำเป็นต้องให้ความรู้พื้นฐานกับระบบล่วงหน้าตัวอัลกอริทึมก็สามารถสร้างแบบจำลองและแก้ไขปัญหาที่ซับซ้อนได้หลากหลายอีกทั้งมีความยืดหยุ่นสูงสำหรับอัลกอริทึมที่ได้รับความนิยมในการจำแนกรูปภาพในปัจจุบันคือ โครงข่ายประสาทคอนโวลูชัน (Convolution Neural Network: CNN




ภาพ 1 โครงสร้าง Deep Learning [2]

2.3 โครงข่ายประสาทคอนโวลูชัน

โครงข่ายประสาทคอนโวลูชัน (Convolution Neural Networks: CNN) เป็นการเรียนรู้ของเครื่องอีกประเภทหนึ่ง


(Machine Learning) ที่ได้จำลองรูปแบบประเภทโครงข่ายประสาทเทียมในรูปแบบการเรียนรู้เชิงลึก (Deep Learning) โดยเริ่มจากกระบวนการสกัดคุณลักษณะที่สำคัญของรูปภาพออกมาโดยใช้ Convolutional Layer ผ่านฟิลเตอร์ในแต่ละชั้นตอนการ Pooling หลังจากนั้นจึงทำการแปลงโครงสร้างของข้อมูลที่ต้องการเรียนรู้ด้วยการ Flatten และเข้าสู่กระบวนการจำแนกด้วยโครงข่ายประสาทเพื่อหาผลลัพธ์ที่ต้องการ ซึ่งตัวโมเดลจะมีความยืดหยุ่นและสามารถสร้างรูปแบบการเรียนรู้ขึ้นมาได้เองโดยที่ผู้ใช้ไม่จำเป็นต้องกำหนดรูปแบบในการเรียนรู้ให้กับตัวโมเดล



ภาพ 2 โครงสร้าง CNN [3]

2.4 Artificial Neural Network

โครงข่ายประสาทเทียม เป็นแบบจำลองทางคณิตศาสตร์ที่พัฒนาเพื่อจำลองการทำงานของโครงข่ายประสาทในสมองของมนุษย์ โมเดลจะให้ค่าน้ำหนักซึ่งจะถูกปรับเปลี่ยนค่า เมื่อมีการเรียนรู้ใหม่ๆ เกิดขึ้น ค่าน้ำหนักเปรียบเสมือนความรู้ที่ถูกรวบรวมขึ้นเพื่อใช้ในการแก้ไขปัญหาในสมองของมนุษย์เหมือนในระบบประสาทของมนุษย์ภายในโหนดจะมีฟังก์ชันกระตุ้นหรือ Activation Function ซึ่งเป็นฟังก์ชันสำหรับส่งสัญญาณส่งออกหรือผลลัพธ์ ภาพจำลองการทำงานของเครือข่ายประสาทเทียมแสดงดังภาพที่ 3



ภาพ 3 โครงสร้างของ ANN [4]

2.5 Object Detection

Object Detection หรือ การตรวจจับวัตถุ เป็นเทคนิคหนึ่งในด้าน Computer Vision ที่ใช้ในการตรวจจับและจำแนกวัตถุในภาพหรือวิดีโอ และยังสามารถบอกตำแหน่งที่แน่นอนของวัตถุเหล่านั้นได้ โดยการแสดงผลในรูปของ bounding box หรือกรอบขอบเขตที่ล้อมรอบวัตถุในภาพพร้อมกับคำจำกัดความของวัตถุแต่ละตัวที่ตรวจพบ

2.6 Yolo

Yolo เป็นหนึ่งในอัลกอริทึมที่ใช้ในการ Object Detection โดยการตรวจจับวัตถุในภาพหรือวิดีโอในลักษณะที่รวดเร็วและมีประสิทธิภาพ โดยที่ Yolo มีความโดดเด่นที่สามารถตรวจจับวัตถุหลายๆชนิดในภาพเดียวกันได้ในครั้งเดียวโดยไม่ต้องทำการประมวลผลหลายขั้นตอนเหมือนกับวิธีการ Object Detection แบบดั้งเดิม เช่น R-CNN หรือ Fast R-CNN

2.7 งานวิจัยที่เกี่ยวข้อง

งานวิจัยของ ไพศาล ฐิติอาภากุล และคณะ (2020) เรื่อง "ตัวต้นแบบการตรวจจับพฤติกรรมเสี่ยงต่อการหลับในจากภาพวิดีโอ" [5] มีเป้าหมายในการพัฒนาระบบต้นแบบสำหรับตรวจจับพฤติกรรมเสี่ยงของผู้ขับขี่ที่อาจนำไปสู่ภาวะหลับใน โดยใช้เทคนิคการคำนวณอัตราส่วนดวงตาผ่าน Euclidean Distance และนำค่าที่คำนวณได้มาใช้ในการทำนายภาวะหลับในระบบที่พัฒนาขึ้นประกอบด้วย 3 ส่วนหลัก ได้แก่

1. การตรวจจับใบหน้าของผู้ขับขี่ จากภาพวิดีโอ
2. การตรวจจับภาวะหลับในโดยวิเคราะห์พฤติกรรม เช่น การลืมตาปกติ การกระพริบตาปกติ อาการตาปรือ การกระพริบตาถี่ ๆ และการหลับตา
3. ระบบแจ้งเตือนด้วยเสียง เพื่อเตือนผู้ขับขี่เมื่อเข้าสู่ภาวะง่วงนอน

ผลการทดลองแสดงให้เห็นว่าโมเดลสามารถตรวจจับพฤติกรรมที่บ่งบอกถึงภาวะหลับในได้ โดยมีความแม่นยำในการตรวจจับอาการหลับตาสูงถึง 76.67% อย่างไรก็ตาม ความแม่นยำในการตรวจจับการกระพริบตาปกติและการกระพริบตาถี่

ๆ ยังอยู่ในระดับต่ำ ซึ่งอาจได้รับผลกระทบจากปัจจัยต่าง ๆ เช่น คุณภาพของกล้องและแสงสว่างในขณะทำการทดลอง

งานวิจัยนี้มีศักยภาพในการนำไปพัฒนาเป็นระบบช่วยเหลือผู้ขับขี่ในอนาคต เพื่อลดความเสี่ยงของอุบัติเหตุที่เกิดจากการหลับใน และสามารถนำไปใช้ร่วมกับระบบความปลอดภัยของยานพาหนะเพื่อเพิ่มความปลอดภัยบนท้องถนน

3. วิธีดำเนินการศึกษา

การตรวจจับพฤติกรรมของผู้ขับขี่ยานพาหนะด้วยรูปภาพและวิดีโอโดยใช้เทคนิคการตรวจจับวัตถุ (Object Detection) มีการดำเนินงาน 4 ขั้นตอนด้วยกัน ได้แก่ 1) การรวบรวมและเตรียมข้อมูล 2) การสร้างโมเดลตรวจจับภาพและวิดีโอ 3) การวัดประสิทธิภาพโมเดล 4) การนำโมเดลมาประยุกต์ใช้

3.1 การรวบรวมและเตรียมข้อมูล

รูปภาพที่ได้มาจาก เว็บไซต์ universe.roboflow.com 4336 รูป, แบ่งข้อมูลแต่ละคลาสเป็น Drinking 902 รูป, Fatigue and somnolence 495 รูป, Reaching behind 329 รูป, Smoking 503 รูป, Talking phone 1145 รูป , Writing message 962 รูป

3.2 การสร้างโมเดลตรวจจับภาพ

การสร้างโมเดลตรวจจับพฤติกรรมของผู้ขับขี่ยานพาหนะ มีขั้นตอนดังนี้ การสร้างโมเดลเริ่มจากนำรูปภาพที่ได้จัดเตรียมไว้ทำการฝึกและสร้างโมเดลด้วยภาษา Python และไลบรารี YOLO โดยโครงสร้างของตัวโมเดลสำเร็จรูปของ Yolo V8s ที่ถูกพัฒนาโดยนักวิจัยจาก University of Washington และ Joseph Redmon

3.3 การวัดประสิทธิภาพโมเดล

ในงานวิจัยนี้ใช้มาตรวัดประสิทธิภาพทั้งหมด 3 ตัวคือค่าความแม่นยำ (Precision) ค่าความระลึก (Recall) และค่าความแม่นยำของโมเดล (mAP) ซึ่งแต่ละค่ามีวิธีการคำนวณดังสมการที่ (1) ถึงสมการที่ (3) ตามลำดับ

$$\text{Precision} = \frac{TP}{TP+TN} \quad (1)$$

$$\text{Recall} = \frac{TP}{TP+FN} \quad (2)$$

$$\text{mAP} = mAP \frac{1}{N} \sum_{i=1}^N AP_i \quad (3)$$

3.4 การนำโมเดลมาปรับใช้

การนำโมเดลจำแนกภาพที่ผ่านการฝึกสอนเรียบร้อยแล้ว มาปรับใช้กับเว็บไซต์ตัวอย่างที่ได้จัดทำขึ้น ผู้วิจัยเขียนด้วยภาษา python บนโปรแกรม google colab ชื่อโปรแกรม Deploy_Model การตรวจจับพฤติกรรมของผู้ขับขี่ยานพาหนะ เพื่อเรียกใช้โมเดลและประมวลผลในเว็บไซต์ ตัวอย่าง ซึ่งไฟล์โมเดลที่ได้จากการฝึกสอนและผ่านการทดสอบประสิทธิภาพแล้ว คือไฟล์ best.pt การเรียกใช้งานโมเดลในโปรแกรม google colab โดยมีการใช้ framework ประกอบดังนี้ ngrok , flask เพื่อเรียกใช้งานโดยการโหลดโมเดลเพื่อมาแสดงผล

4. ผลการศึกษาและการอภิปรายผล

ในส่วนของผลการศึกษา ผู้วิจัยแบ่งผลการศึกษาเป็น 2 ส่วน คือ ส่วนของการเปรียบเทียบประสิทธิภาพของอัลกอริทึม YOLO จำนวน 2 โมเดล และส่วนของการนำโมเดลไปพัฒนาเว็บแอปพลิเคชันซึ่งมีรายละเอียดดังนี้

4.1 ผลการวัดประสิทธิภาพโมเดล

การศึกษานี้ได้ทดลองเปรียบเทียบการสร้างโมเดลโดยใช้ YOLO ตรวจจับวัตถุ ซึ่งผู้วิจัยได้ทำการทดลองกับอัลกอริทึมโมเดล YOLOV8S เพื่อจำแนกคำตอบเป็น 6 คลาส คือ WRITTING MESSAGE, FATIGUE AND SOMNOLENCE, SMOKING, TALKING PHON, DRINKING และ REACHING BEHIND จำแนกรูปภาพจำนวนทั้งสิ้น 4,336 ภาพ เมื่อรวมกับภาพที่ทำ AUGMENTATION แล้วจะเป็น 17,344 ภาพโดยผู้วิจัยได้แบ่งชุดข้อมูลออกเป็น 3 ชุด คือ ชุดข้อมูลฝึกจำนวนร้อยละ 80 ชุดข้อมูลทดสอบการฝึกจำนวนร้อยละ 10 และชุดข้อมูลทดสอบจำนวนร้อยละ 10 จากข้อมูลทั้งหมด และวัดประสิทธิภาพด้วยมาตรวัดจำนวน 5 มาตรวัด หลังจากนั้นจะนำ

ผลของการตรวจจับวัตถุของทั้งสอง MODEL มาเปรียบเทียบประสิทธิภาพและคัดเลือกอัลกอริทึมที่ให้ค่าประสิทธิภาพที่สูงที่สุดนำไปพัฒนาแอปพลิเคชันต่อไป ผลการเปรียบเทียบแสดงในตารางที่ 2 จากตารางที่ 2 โดย MODEL แรกให้ค่าความแม่นยำ (PRECISION) เท่ากับ 0.99 ค่าความระลึก (RECALL) เท่ากับ 0.98 ค่าความถ่วงดุล (F1-SCORE) เท่ากับ 0.98 ค่าความแม่นยำเฉลี่ย (MAP@50) เท่ากับ 0.99 และค่าความแม่นยำเฉลี่ย (MAP@50-95) เท่ากับ 0.93 MODEL ที่สองให้ค่าความแม่นยำ (PRECISION) เท่ากับ 0.89 ค่าความระลึก (RECALL) เท่ากับ 0.87 ค่าความถ่วงดุล (F1-SCORE) เท่ากับ 0.88 ค่าความแม่นยำเฉลี่ย (MAP@50) เท่ากับ 0.93 และค่าความแม่นยำเฉลี่ย (MAP@50-95) เท่ากับ 0.67 แต่ด้วย MODEL ที่สองมีการตรวจจับคู่กับ KEYPOINT MEDIAPIPE POSE จึงถูกนำมาใช้ในการพัฒนาต่อยอดสำหรับการตรวจจับวัตถุบนเว็บแอปพลิเคชันต่อไป ภาพที่ 4 แสดง learning curve ของ model ที่ 1 และภาพที่ 5 แสดง learning curve ของ model ที่ 2


ตารางที่ 2 การเปรียบเทียบประสิทธิภาพของโมเดล

Algorithm Measure	YOLOV8S	YOLOV8S + MEDIAPIPE POSE
PRECISION	0.99	0.89
RECALL	0.98	0.87
F1-SCORE	0.98	0.88
MAP@50	0.99	0.93
MAP@50-95	0.93	0.67


5. บทสรุป

งานวิจัยนี้แนะนำการใช้เทคนิค Object Detection เพื่อตรวจจับหรือจำแนกผู้ขับขี่ว่าเป็นการขับขี่ที่ก่อให้เกิดอันตรายหรือไม่ โดยประยุกต์ใช้กับโมเดลที่มีความรวดเร็วอย่าง Yolo ในการสร้างโมเดลที่สามารถเรียนรู้ลักษณะเฉพาะการตรวจจับวัตถุของภาพหรือวิดีโอของผู้ขับขี่ได้อย่างมีประสิทธิภาพ การดำเนินงานเริ่มจากการรวบรวมชุดข้อมูลภาพเหตุการณ์การขับขี่จำนวนทั้งสิ้น 4,336 ภาพ ซึ่งแบ่งเป็น 6 คลาส ได้แก่ Drinking 902 รูป, Fatigue and somnolence 495 รูป, Reaching behind 329 รูป, Smoking 503 รูป, Talking phone 1145 รูป , Writing message 962 รูป จากนั้นนำข้อมูลดังกล่าวมาฝึกสอนกับ YOLOv8s เป็นจำนวน 40 รอบ เพื่อให้โมเดลสามารถเรียนรู้และจดจำคุณลักษณะที่เป็นเอกลักษณ์ของแต่ละเหตุการณ์การขับขี่ได้อย่างละเอียด จากการทดสอบพบว่าโมเดลที่ได้มีความสามารถในการจำแนกตรวจจับอย่างแม่นยำถึง $mAP@50 = 93.29\%$, $mAP@50-95 = 67.29\%$ ผลการทดลองแสดงให้เห็นว่าเทคนิค Object Detection มีศักยภาพในการช่วยแก้ปัญหาการจำแนกเหตุการณ์การขับขี่ และสามารถนำไปใช้ประโยชน์ในอุตสาหกรรมอย่างมีประสิทธิภาพ ทั้งนี้ยังสามารถต่อยอดไปสู่การพัฒนาระบบสารสนเทศที่ช่วยเพิ่มความปลอดภัยของผู้ขับขี่ได้อย่างรวดเร็วและแม่นยำ ซึ่งจะช่วยลดอุบัติเหตุที่จะเกิดขึ้นได้ในขณะขับรถ

อย่างไรก็ตาม แม้ว่าผลลัพธ์จะมีความแม่นยำในระดับที่ยอมรับได้ แต่ยังมีข้อจำกัดที่สำคัญในเรื่องความซับซ้อนของโมเดลที่ส่งผลให้การประมวลผลใช้ทรัพยากรสูง รวมถึงประสิทธิภาพของโมเดลที่ ยังคงมีขอบเขตจำกัด ดังนั้นข้อเสนอแนะสำหรับการวิจัยในอนาคตคือการปรับปรุงโครงสร้างของโมเดลเพื่อเพิ่มความเร็วในการประมวลผล รวมถึงการเพิ่มคุณภาพของชุดข้อมูลที่ใช้ในการฝึกสอน เช่น การเพิ่มความหลากหลายของภาพในสถานะแสงที่แตกต่างกัน เพิ่มภาพที่มีมุมกล้องที่หลากหลาย เพื่อช่วยให้โมเดลมีความแม่นยำสูงขึ้นและสามารถนำไปประยุกต์ใช้ในสภาพแวดล้อมที่หลากหลายได้มากขึ้น



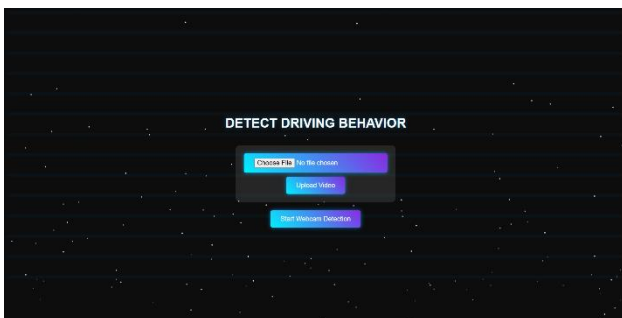
ภาพ 4 learning curve ของ model ที่ 1



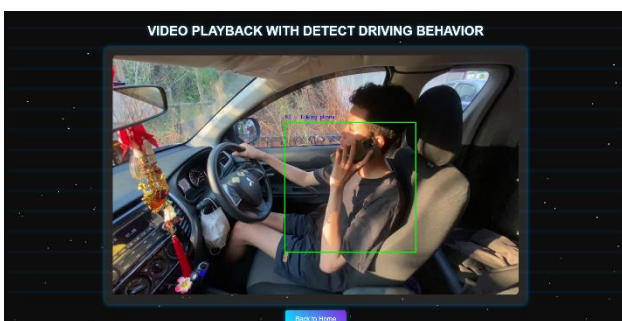
ภาพ 5 learning curve ของ model ที่ 2

4.2 ผลการพัฒนาเว็บไซต์

ผลลัพธ์ของการพัฒนาระบบตรวจจับพฤติกรรมเสี่ยงของผู้ขับขี่มีรายละเอียดดัง ภาพที่ 6 ซึ่งแสดงหน้าเว็บไซต์ที่พัฒนาขึ้น โดยผู้ใช้งานสามารถอัปโหลดวิดีโอของผู้ขับขี่เข้าสู่ระบบเพื่อให้โมเดลทำการจำแนกพฤติกรรมที่อาจเป็นอันตรายระหว่างการขับขี่ หากตรวจพบ การใช้โทรศัพท์ขณะขับขี่ ระบบจะแสดงผลลัพธ์ตาม ภาพที่ 7



ภาพ 6 หน้าเว็บไซต์หลัก



ภาพ 7 หน้าเว็บไซต์เมื่อผลลัพธ์เป็นการใช้โทรศัพท์ขณะขับขี่

เอกสารอ้างอิง

- [1] A Proposed Deep Learning Model for Classification of Some Fish Species ,[ออนไลน์]2566 สืบค้นเมื่อวันที่ 9 มีนาคม 2568. จาก.
https://www.researchgate.net/publication/360894758_IsVoNet8_A_Proposed_Deep_Learning_Model_for_Classification_of_Some_Fish_Species%E2%80%8B
[B](https://www.researchgate.net/publication/360894758_IsVoNet8_A_Proposed_Deep_Learning_Model_for_Classification_of_Some_Fish_Species%E2%80%8B)
- [2] Backpropagation neural network with two hidden layers., [ออนไลน์] 2565. สืบค้นเมื่อวันที่ 9 มีนาคม 2568. จาก.
https://www.researchgate.net/figure/Backpropagation-neural-network-with-two-hidden-layers_fig2_275467483
- [3] Pengertian dan Cara Kerja Algoritma Convolutional Neural Network (CNN)., [ออนไลน์] 2556. สืบค้นเมื่อวันที่ 9 มีนาคม 2568. จาก.
<https://www.t5ivusi.web.id/2022/04/algoritma-cnn.html>
- [4] Scientists Developed a “Synthetic Neuron” that Can Hold Electronic Memories., [ออนไลน์] 2565. สืบค้นเมื่อวันที่ 9 มีนาคม 2568. จาก.
<https://engineeringexploration.com/scientists-developed-a-synthetic-neuron-that-can-hold-electronic-memories/>
- [5] ตัวต้นแบบการตรวจจับพฤติกรรมเสี่ยงต่อการหลับในจากภาพวิดีโอ The prototype of detecting risky behavior of drowsiness from video 2563. สืบค้นเมื่อวันที่ 10 กุมภาพันธ์ 2568. จาก.
https://ph02.tcithaijo.org/index.php/RJST/article/download/244308/165610?utm_source=chatgpt.com